

1. Ce que le projet attend de toi

Le projet porte sur une mission d'analyse de données pour **BottleNeck**, un marchand de vin. Tu joues le rôle d'un analyste chargé de nettoyer, consolider et analyser des fichiers issus de plusieurs sources : ERP, site web WordPress et table de liaison. L'objectif final est de produire un travail clair pour un **CODIR**, donc pas seulement technique, mais aussi compréhensible par une équipe de direction.

Les compétences visées sont bien orientées **BI / Supply Chain / Data Analyst** : exploration de fichiers, nettoyage, jointures, analyses univariées, utilisation d'un notebook Python ou R, puis présentation des résultats.

2. Les livrables obligatoires

Il y a seulement **2 livrables à rendre** :

Livable		Format attendu	Contenu attendu
1		Notebook Python ou R	Nettoyage, consolidation, analyses, graphiques, contrôles
2		Présentation, 20 slides maximum	Méthodologie, analyses, recommandations ERP

Le fichier précise aussi le nommage attendu dans un dossier ZIP :

Titre_du_projet_nom_prénom, avec des fichiers du type Nom_Prenom_1_notebook_mmaaaa et Nom_Prenom_2_presentation_mmaaaa.

Donc contrairement à certains autres projets, il n'y a **pas de rapport Word/PDF séparé demandé**. Tout doit être porté par le notebook et la présentation.

3. La mission principale

La mission est découpée en **2 phases**.

Phase 1 — Préparer et fiabiliser les données

Tu dois :

- rapprocher les données ERP avec celles du site web grâce à la table de liaison ;
- repérer les erreurs dans les données ;
- documenter au moins **8 erreurs ou anomalies** ;
- proposer des solutions pour améliorer la qualité des données dans les systèmes.

Les erreurs attendues peuvent être de plusieurs types :

TYPE D'ERREUR	EXEMPLE POSSIBLE
ERREUR DE JOINTURE	SKU absent de la table de liaison
ERREUR DE SAISIE	Prix incohérent, stock négatif
ERREUR DE TYPE	Prix lu comme texte au lieu de nombre

VALEUR MANQUANTE	Produit sans prix, sans stock ou sans vente
DOUBLON	Référence présente plusieurs fois
ERREUR DE CALCUL	CA ou marge incohérents
VALEUR ABERRANTE	Prix très élevé ou très bas
INCOHERENCE METIER	Produit vendu mais stock ou liaison manquante

Cette phase est très importante, car Nicolas précise que l'entreprise veut comprendre les erreurs rencontrées pour préparer un futur projet de data visualisation.

4. Les analyses demandées

La phase 2 correspond aux analyses à présenter au CODIR.

Les analyses obligatoires sont :

ANALYSE DEMANDEE	CE QU'IL FAUT PRODUIRE
CHIFFRE D'AFFAIRES PAR PRODUIT	CA = prix × quantité vendue
CHIFFRE D'AFFAIRES TOTAL	Somme globale du CA
TOPS REFERENCES	Produits qui génèrent le plus de CA ou de ventes
ANALYSE 20/80	Vérifier si 20 % des produits génèrent environ 80 % du CA
VALEURS ABERRANTES	Détection avec Z-score ou écart interquartile
BOXPLOT DES PRIX	Visualisation des prix atypiques
ANALYSE DES STOCKS	État du stock, rotation, mois de stock
ANALYSE DES MARGES	Taux de marge, marge brute
CORRELATIONS	Prix, prix d'achat, stock, ventes, prix HT, marge, etc.

Le scénario insiste aussi sur la nécessité de conclure : il ne suffit pas de sortir des chiffres, il faut dire ce qu'ils signifient pour l'entreprise.

5. Les questions probables en soutenance

Pendant la soutenance, l'évaluateur jouera le rôle de Nicolas. Il posera des questions sur les livrables et sur tes choix méthodologiques. Les questions annoncées portent notamment sur :

- la fiabilité des données ;
- les données manquantes ;
- le choix entre corriger, exclure ou conserver certaines données ;
- la valorisation des stocks ;
- la conformité RGPD.

Il faudra donc être capable d'expliquer simplement :

“J’ai conservé les données exploitables, corrigé les erreurs évidentes quand une règle métier permettait de le faire, et isolé les anomalies non vérifiables pour éviter de fausser les analyses.”

Pour le RGPD, à première vue, les fichiers semblent surtout contenir des données produits, stock et ventes. Donc le risque RGPD paraît faible, sauf présence de données personnelles dans les fichiers réels. Il faudra vérifier dans le notebook qu’il n’y a pas de noms clients, emails, téléphones, adresses ou identifiants personnels.

6. Structure recommandée pour ton notebook

Ton notebook doit raconter une histoire claire, pas seulement afficher du code.

Structure idéale :

1. Introduction

- contexte BottleNeck ;
- objectif de la mission ;
- fichiers utilisés.

2. Import des librairies

- pandas ;
- numpy ;
- matplotlib / seaborn ;
- scipy si besoin pour le Z-score.

3. Chargement des fichiers

- ERP ;
- web ;
- liaison.

4. Exploration initiale

- dimensions des fichiers ;
- types de colonnes ;
- valeurs manquantes ;
- doublons ;
- aperçu des données.

5. Nettoyage

- correction des types ;
- gestion des valeurs manquantes ;
- contrôle des doublons ;

- normalisation des colonnes ;
- contrôle des clés de jointure.

6. Consolidation

- jointure ERP / liaison ;
- jointure avec les données web ;
- vérification des produits non rapprochés.

7. Détection des anomalies

- prix aberrants ;
- stock incohérent ;
- références non liées ;
- erreurs de saisie ;
- écarts de données.

8. Analyses métier

- CA par produit ;
- CA total ;
- top produits ;
- 20/80 ;
- marges ;
- stocks ;
- rotation ;
- corrélations.

9. Recommandations ERP

- contrôles à mettre en place ;
- règles de saisie ;
- automatisation des rapprochements ;
- alertes sur stocks et prix ;
- dictionnaire de données.

10. Conclusion

- synthèse des résultats ;
- limites ;
- prochaines étapes.

7. Structure recommandée pour la présentation — 20 slides maximum

Je te conseille une présentation en **18 à 20 slides**, claire et CODIR-compatible.

SLIDE CONTENU

1	Titre + contexte BottleNeck
2	Objectifs de la mission
3	Sources de données utilisées
4	Problème principal : données dispersées
5	Méthodologie globale
6	Rapprochement ERP / Web / Liaison
7	Qualité des données : erreurs détectées
8	Exemples d'anomalies corrigées ou isolées
9	Chiffre d'affaires total
10	CA par produit / top références
11	Analyse 20/80
12	Analyse des prix et valeurs aberrantes
13	Boxplot des prix
14	Analyse des stocks
15	Rotation ou mois de stock
16	Analyse des marges
17	Corrélations entre variables
18	Recommandations pour l'ERP
19	Réponses aux risques : fiabilité, RGPD, données manquantes
20	Conclusion finale

Important : comme la soutenance dure **15 minutes**, il faudra viser environ **40 à 45 secondes par slide** maximum.

8. Ce qu'il faudra absolument démontrer au jury

Pour viser une bonne note, il faudra montrer que tu sais :

- nettoyer les données sans les modifier au hasard ;
- justifier tes choix ;
- faire des jointures fiables ;
- détecter les erreurs ;

- analyser le chiffre d'affaires et les stocks ;
- repérer les produits stratégiques ;
- proposer des améliorations concrètes pour l'ERP ;
- vulgariser les résultats pour des non-techniciens.

Le point fort à mettre en avant :

tu ne fais pas seulement des calculs, tu transformes des fichiers dispersés et imparfaits en une base exploitable pour piloter l'activité.